

Unidad 3

Representación de texto

Organización del Computador I

Lic. en Sistemas - Tec. Sup. en Informática

Codificación de caracteres

La representación de caracteres se realiza mediante el uso de una codificación que asigna un valor a cada carácter que puede ser almacenado o transmitido por una red.

Por lo general es un valor entero representado por una secuencia de bits.

Códigos de Representación

- EBCDIC
- ASCII
- UNICODE
- UTF-8
- UTF-16
- Convenciones (C, Pascal)

EBCDI

El código EBCDIC es una extensión del código BCD diseñado por IBM en la década del '60.

Codifica directamente caracteres de texto usando 8 bits por cada uno. Usados de la siguiente manera

$b_7 b_6$	$b_5 b_4$	$b_3 b_2 b_1 b_0$
00 reservado	00 de la A a la I	carácter en binario
01 caract especiales	01 de la J a la R	
10 minúsculas	10 de la S a la Z	
11 mayúsc y núm	11 del 0 al 9	

ASCII

American Standard Code for Information Interchange

Nació a partir de reordenar y expandir el conjunto de símbolos y caracteres usados en telegrafía (1963)

- Codifica letras, dígitos, signos de puntuación y caracteres de control usa 7 bits permitiendo 128 combinaciones.
- 8 bits → 128 caracteres conteniendo todos lo necesario para escribir en idioma inglés.

ASCII Extendido

IBM desarrolló una extensión de 8 bits del código ASCII, llamada "página de código 437" que utiliza 8 bits para poder representar más caracteres, soluciona problemas para representar otros idiomas.(1981)

- Las primeras PC'S usaban representaciones de 1 byte.
- US-ASCII para los bytes de 0 a 127.
- Del 128 al 255 los bytes se utilizaron para incluir caracteres de otras lenguas:
 - Acentos: ú, á, å, ç
 - Ñ, £, ñ, ä
 - Letras griegas α , β , δ



ASCII Codificaciones Stándar

Codificación	Lenguaje/País
CP437	EEUU
CP850	Multilingüe Europa occidental
Windows1252	
Latin 1 ISO 8859-1	
CP855	Cirílico (Ruso)
CP862	Hebreo
CP720	Árabe

Desventajas representaciones de 1 byte

- Combinar distintos lenguajes en un mismo documento.
- Hay lenguajes que tienen más de 255 caracteres (chino)
- No se pueden combinar distintas reglas ortográficas y lexicográficas.
- No se pueden representar letras de distintas manera.
- Para visualizar correctamente un texto hay que saber la página de códigos utilizada.



Cómo representar una Mayúscula? Y su minúscula?

Dec	Hex	Oct	Chr	Dec	Hex	Oct	HTML	Chr	Dec	Hex	Oct	HTML	Chr
0	0	000	NULL	64	40	100	@	␣	96	60	140	`	␣
1	1	001	Start of Header	65	41	101	A	A	97	61	141	a	a
2	2	002	Start of Text	66	42	102	B	B	98	62	142	b	b
3	3	003	End of Text	67	43	103	C	C	99	63	143	c	c
4	4	004	End of Transmission	68	44	104	D	D	100	64	144	d	d
5	5	005	Enquiry	69	45	105	E	E	101	65	145	e	e
6	6	006	Acknowledgment	70	46	106	F	F	102	66	146	f	f
7	7	007	Bell	71	47	107	G	G	103	67	147	g	g
8	8	010	Backspace	72	48	110	H	H	104	68	150	h	h
9	9	011	Horizontal Tab	73	49	111	I	I	105	69	151	i	i
10	A	012	Line feed										
11	B	013	Vertical Tab										

- 1- Pararse en inicio del código posición 0 ₍₁₆₎
- 2- Sumar 41 ₍₁₆₎ → “A” Mayúscula
- 3- Pararse en la posición del símbolo a representar ej:41 ₍₁₆₎
- 4-Sumar 20 ₍₁₆₎ → para obtener código de su minúscula “a”

Ejemplo:

Character	1		E	I	e	f	a	n	t	e
ASCII (Hexadecimal)	31	20	45	6C	65	66	61	6E	74	65

Character	0	3	0	3		4	5	6	\0	^
ASCII (Hexadecimal)	30	33	30	33	20	34	35	36		5E

Para pensar y responder:

- Cuando represento valores numéricos decimales de un dígito, cuánto debe sumar desde el origen del código?
- Cómo pasar de minúscula a Mayúscula?

UNICODE - Unicode Transformation Format

Distintos fabricantes de la industria crean un estándar para unificar todos los lenguajes de uso histórico.

Codepoint: número asignado a cada caracter o símbolo. Actualmente van desde 0 a 10FFFF₍₁₆₎.

Formas de codificación bajo el nombre UTF

- UTF 8
- UTF 16
- UTF 32

UNICODE

Incluye caracteres modificadores que se combinan.

- Los *code-points* del 0 al 127 coinciden con la tabla ASCII.
- Desde 0 hasta 255 coincide con ISO 8859-1.
- Los caracteres de distintos lenguajes están agrupados en bloques.

El rango de caracteres está dividido en distintos planos.

Rango	Plano
00000 - 0FFFF	0 - Plano Básico Multilingüe (BMP)
10000 - 1FFFF	1 - Plano Multilingüe Suplementario
20000 - 2FFFF	2 - Plano Suplementario Ideográfico

UTF 8

- Es una codificación donde cada caracter ocupa uno o más bytes (hasta 4 bytes)
- Los caracteres de ASCII se representan con 1 byte
- Caracteres del plano básico multilingüe hasta 3 bytes.

Número de bytes	Bits para el código de caracteres	Primer código	Último código	Byte 1	Byte 2	Byte 3	Byte 4
1	7 (ASCII)	U+0000	U+007F	0xxxxxxx			
2	11	U+0080	U+07FF	110xxxxx	10xxxxxx		
3	16	U+0800	U+FFFF	1110xxxx	10xxxxxx	10xxxxxx	
4	21	U+10000	U+10FFFF	11110xxx	10xxxxxx	10xxxxxx	10xxxxxx

UTF 16

El formato UTF-16 se basa en unidades de código de 16 bits. Cada carácter puede tener 16 bits (2 bytes) o 32 bits (4 bytes).

Los caracteres de sustitución utilizan 4 bytes , por lo tanto, requieren almacenamiento adicional. Estos caracteres también pueden almacenarse en UTF-8 o en UTF-32, pero como siempre necesitan 4 bytes de almacenamiento, ninguno de estos formatos permite ahorrar espacio.



Codificación UTF - Ejemplos

Elemento de código Unicode	ASCII	UTF-8	UTF-16 (formato Big Endian) ¹	UTF-32 (formato Big Endian)	
A	U+0041	X'41'	X'41'	X'0041'	X'00000041'
a	U+0061	X'61'	X'61'	X'0061'	X'00000061'
9	U+0039	X'39'	X'39'	X'0039'	X'00000039'
Å	U+00C5	X'C5'	X'C385' ²	X'00C5'	X'000000C5'
類	U+9860	X'CDDB' (CCSID 939)	X'E9A1A0'	X'9860'	X'00009860'
ㄗ	U + 200D0	No existe	X'F0A08390'	X'D840DCD0'	X'000200D0'

1-z/OS utiliza únicamente el formato big endian. El formato little endian se utiliza en otros sistemas operativos

<https://www.ibm.com/docs/es/db2-for-zos/11?topic=unicode-utfs>

Cadenas de Caracteres Convención C (ASCII-Z)

Asumimos una codificación de 1 Byte.

- Cada cadena es una secuencia de bytes que *finaliza en el byte 0 (NULL)*.
- La longitud de una cadena es desconocida ,no acotada.
- Para calcular la longitud de una cadena hay que recorrerla.



El ejemplo en la diapositiva 9, aplica esta convención.

Cadenas de Caracteres Convención Pascal

- El 1er Byte de la cadena de caracteres indica la longitud de la misma.
- Una cadena no puede tener más de 255 caracteres.
- Usando 2 Bytes para la long., la long. Máxima sería de 65535.